

姓名：郑凯元

学号：B230200149

## 基于支持向量机(SVM)的选取激光熔化技术工艺优化

**摘要** 采用基于支持向量机(SVM)的高效优化方法，对难焊接镍基高温合金 Inconel 713 的选取激光熔化(SLM)进行了工艺参数优化。提取了制备 SLM 样品的全局最优条件，采用优化条件制备的样本表面平整，内部无裂纹和气孔。结果表明，该方法对 SLM 过程的优化是有效的，特别是在同时考虑多个参数的情况下。

### 1.研究背景及意义

选取激光熔化（SLM）是如今最常用的增材制造技术之一，广泛应用于航空航天、医疗和汽车领域。与传统制造相比，SLM 具有明显的优势，例如：制造时间更快，生产成本更低，多功能性更高。但 SLM 仍面临一系列挑战，例如：尺寸精度较低，表面粗糙度较低，存在孔隙和裂纹等。尤其是在使用 Inconel 713 和 Inconel 738 等高裂纹敏感性材料进行增材制造时。在这些材料中，Inconel 713 是航空航天领域的常见铸造材料，因其在高温下具有高拉伸强度、良好的疲劳强度和良好的抗蠕变性而在工业领域得到广泛应用。但 Inconel 713 作为一种难焊接材料，很容易在凝固收缩阶段产生晶间液化裂纹和表面裂纹。因此本文采用支持向量机(SVM)优化方法，对难焊接 Inconel 713 材料的 SLM 工艺条件进行了优化。为了验证这种优化方法，我们同时优化了三个工艺参数，即激光功率、扫描速度和线间距。优化后，在全局最优条件下制备样品。通过对缺陷的表征，我们证明了该优化方法是解决高维工艺参数优化问题和寻找全局最优的有力工具，这是获得具有理想微观结构和优异力学性能的 SLM 样品的先决条件。

### 2.实验设计与机器学习模型

#### 2.1 实验设计

由于 SLM 技术成形工艺复杂，不同工艺参数对成形质量的影响也存在差异，需要进行大量的实验，以寻找匹配的工艺参数。而通过均匀实验设计，可以用于研究各种工艺参数对零件质量及特性的影响，并减少试验次数，降低实验成本。本实验针对工艺参数对成形质量的影响展开研究，因此主要设计激光功率、扫描速度和线间距三个参数，通过均匀实验设计设计激光功率、扫描速度和线间距的 30 组参数，使其均匀分布在参数空间内。实验所采用的选区激光熔化成形的

工艺参数如表 1 所示。

表 1 选区激光熔化成形的工艺参数

实验序号	功率/W	扫描速度/mm/s	线间距/mm
1	178	751	0.129
2	118	1379	0.087
3	298	1331	0.108
4	238	1476	0.151
5	208	654	0.140
6	313	799	0.023
7	373	848	0.156
8	163	123	0.049
9	418	171	0.145
10	283	413	0.177
11	343	1089	0.135
12	88	1186	0.119
13	478	1138	0.071
14	268	1041	0.055
15	253	219	0.076
16	133	364	0.103
17	148	993	0.172
18	103	606	0.039
19	73	268	0.161
20	193	1234	0.028
21	223	509	0.092
22	403	703	0.081
23	58	896	0.065
24	493	558	0.124
25	433	944	0.097
26	328	74	0.113
27	358	461	0.060
28	448	1283	0.167
29	463	316	0.033
30	388	1428	0.044

2.2 机器学习模型

机器学习是计算机科学与统计学结合的产物，主要研究如何从大量已经数据中学习特定经验构建模型。支持向量机(Support Vector Machine, SVM)是 1995 年贝尔实验室的研究小组提出的一种新的机器学习方法，与传统机器学习相比，SVM 具有小样本、结构简单，适应性好、训练速度快、泛化能力强、可预测全局最优等诸多优势，是降低成本提高准确率寻找最优工艺参数的可靠计算方法。

SVM 是一种强大的机器学习算法,典型的 SVM 是一种二分类算法，其基本

思想是:空间中的样本点集合, 用一个超平面将样本分成两部分, 而 SVM 的优化目标就是找到这样一个超平面, 使得空间中距离超平面最近的点到超平面的集合间隔尽可能大从而实现样本的分类。如图 1 所示, 红色点和绿色点分别代表两类数据样本;  $H$  代表分类超平面;  $H_1$  和  $H_2$  分别代表数据样本中离  $H$  最近且平行于  $H$  的面,  $H_1$  和  $H_2$  之间的距离称为分类间隔。  $H$  面不但能将  $H_1$  和  $H_2$  这两类样本正确分开, 而且使  $H_1$  和  $H_2$  之间的分类距离最大,  $H_1$  和  $H_2$  上的数据样本点被称为支持向量。




图 1 支持向量机原理示意图

给定样本集合  $D = \{(\vec{x}_1, y_1), (\vec{x}_2, y_2), \dots, (\vec{x}_m, y_m)\}$ , 设  $y_i \in \{-1, +1\}$ 。其中  $y_i$  的值为 1 或者 -1, 表示点所属的类别。设输入空间的一个超平面表示为:

$$\vec{w}^T \vec{x} + b = 0$$

其中  $\vec{w}$  为法向量, 决定超平面的方向;  $b$  为偏置, 决定超平面的位置。空间中一点  $\vec{x}_1$  到超平面  $\vec{w}^T \vec{x} + b = 0$  的欧式距离为:

$$r_i = \frac{|\vec{w}^T \vec{x} + b|}{\|\vec{w}\|}$$

如果超平面能将所有样本点正确分类, 则点到直线的距离可以写作:

$$r_i = \frac{\vec{w}^T \vec{x} + b}{\|\vec{w}\|} y_i$$

SVM 模型中最优超平面的求解是一个典型的带有约束条件的优化问题, 约束条件是所获得的超平面能够将样本集中的点正确分类。那么距离超平面最近的点与超平面的距离则记为:

$$r = \min_{i=1,2,\dots,m} r_i$$

求解最优超平面的问题则为:

$$\max_{\vec{w}, b} r$$

$$s.t. r_i = \frac{\vec{\omega}^T \vec{x} + b}{\|\vec{\omega}\|} y_i \geq r, i = 1, 2, \dots, m$$

但由于实际的样本中往往存在噪声，即正类中混入少量负类样本，负类中混入少量正类样本，使得数据线性不可分。即使样本集合能够线性可分，分类界面的 H1 和 H2 之间的距离可能非常小。这意味着模型的泛化能力降低，从而产生过拟合。因此为了避免过拟合，希望 H1 和 H2 之间的距离尽可能的大，这时可以允许部分样本越过 H1 和 H2。

在线性可分向量机的基础上引入松弛变量  $\delta_i \geq 0$ ，对于样本点  $(\vec{x}_1, y_1)$ ，允许部分样本落入超平面 H1 和 H2，则样本需满足式：

$$(\vec{\omega}^T \vec{x} + b)y_i \geq 1 - \delta_i$$

线性可分支持向量机中，要求所有样本满足  $(\vec{\omega}^T \vec{x} + b)y_i \geq 1$ ，此时 H1 和 H2 之间的距离则为  $\frac{2}{\|\vec{\omega}\|}$ ，被称为“硬间隔”。而  $(\vec{\omega}^T \vec{x} + b)y_i \geq 1 - \delta_i$  中，允许部分样本越过超平面 H1 或 H2，此时 H1 和 H2 之间的距离  $\frac{2}{\|\vec{\omega}\|}$  被称为“软间隔”。在进行超平面最优求解时一方面希望“软间隔”尽量大，使不同类别的样本有明显的分界处。另一方面希望越过超平面 H1 和 H2 的样本尽可能不要远离这两个超平面。此时式为：

$$\begin{aligned} \min_{\vec{\omega}, b, \delta} & \frac{1}{2} \|\vec{\omega}\|^2 + C \sum_{i=1}^m \delta_i \\ s.t. & (\vec{\omega}^T \vec{x} + b)y_i \geq 1 - \delta_i, i = 1, 2, \dots, m \\ & \delta_i \geq 0, i = 1, 2, \dots, m \end{aligned}$$

其中 C(Cost Parameter)为惩罚系数。 $\frac{1}{2} \|\vec{\omega}\|^2$  使得 H1 和 H2 之间的距离尽可能大，而  $\sum_{i=1}^m \delta_i$  则使得越过 H1 或 H2 的样本点离超平面尽可能的近，C 值就是对两者关系的权衡。

以上是针对线性可分问题，但实际应用中经常遇到线性不可分的数据集合。因此对于输入空间  $\Psi$  内样本点存在线性不可分的问题，通常使用一个映射函数将样本集合映射到线性可分的特征空间 H 中，这个特征空间也被称为希尔伯特空间，映射函数则为：

$$\vec{z} = \Phi(\vec{x}): \Psi \rightarrow H$$

在特征空间内使用线性可分算法获得的超平面则为：

$$\vec{\omega}^T \vec{z} + b^* = 0$$

此时 SVM 的决策函数为:

$$f(x) = \text{sgn}(\vec{\omega}^T \vec{z} + b_z^*) = \text{sgn}(\vec{\omega}^T \Phi(\vec{x}) + b_z^*)$$

但现实应用中,难以找到该映射函数中 $\Phi(\vec{x})$ ,使得其在特征空间内线性可分,因而通常使用 $\kappa(\vec{x}_1, \vec{x}_2)$ 代替  $\Phi(\vec{x}_i)^T \Phi(\vec{x}_j)$ 进行求解,即:

$$\kappa(\vec{x}_1, \vec{x}_2) = \Phi(\vec{x}_i)^T \Phi(\vec{x}_j)$$

其中,  $\kappa$ 为核函数。此时式为:

$$\begin{aligned} \min_{\vec{\omega}, b} \quad & \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m \alpha_i \alpha_j y_i y_j \kappa(\vec{x}_i, \vec{x}_j) - \sum_{i=1}^m \alpha_i \\ \text{s.t.} \quad & \sum_{i=1}^m \alpha_i y_i = 0 \\ & 0 \leq \alpha_i \leq C, i = 1, 2, \dots, m \end{aligned}$$

相应的决策函数为:

$$f(x) = \text{sgn}(\vec{\omega}^T \Phi(\vec{x}) + b^*) = \text{sgn}\left(\sum_{i=1}^m \alpha_i y_i \kappa(\vec{x}_i, \vec{x}_j) + b^*\right)$$

经常使用的核函数主要有:线性核函数、多项式核函数、高斯核函数等。本课程使用高斯核函数,即:

$$\kappa(\vec{x}_i, \vec{x}_j) = \exp\left(-\frac{\|\vec{x}_i - \vec{x}_j\|^2}{2\sigma^2}\right)$$

其中  $\sigma$  为超参数,高斯核函数又被称为径向基(RBF)函数。

径向基(RBF)核函数在 SVM 分类模型中,可以使数据更容易被分类或者回归,更如的拟合数据,从而避免过拟合或欠拟合。C 值越大,意味着分类越严格不能有错误,类正确率越高,但此时, SVM 的泛化能力较低,对样本数目比较大的数据集分类结果太理想。因此要选取合适的 C 值,在确保正确率的同时,防止过拟合和欠拟合。

### 3.SLM 零件上表面质量表征

对熔覆层表面进行宏观形貌分析前需对其进行一定的预处理。利用超声波清洗仪清洗熔覆层表面上的金属粉末和其他杂质,使用无水乙醇清洗试样表面,吹干后放置在如图所示的光学显微镜下观察,可以观察到熔覆层表面是否存在未熔

合、球化等缺陷。

针对零件上表面质量，将不同工艺参数下成形的零件分为“优”的和“劣”两个类别。若零件上表面平整光滑，如图 2 所示，则将其分类为“1”判定为质量“优”；若零件上表面存在未熔合、球化等缺陷，如图 3、4 所示，则归为“-1”判定为质量“劣”。分类结果如表 2 所示。




图 2 表面平整光滑




图 3 表面未熔合




图 4 表面球化

表 2 选区激光熔化成形的工艺参数

实验序号	功率/W	扫描速度/mm/s	线间距/mm	分类
1	178	751	0.129	-1
2	118	1379	0.087	-1
3	298	1331	0.108	-1
4	238	1476	0.151	-1
5	208	654	0.140	-1
6	313	799	0.023	-1
7	373	848	0.156	-1
8	163	123	0.049	1
9	418	171	0.145	1
10	283	413	0.177	-1
11	343	1089	0.135	-1
12	88	1186	0.119	-1
13	478	1138	0.071	-1
14	268	1041	0.055	-1
15	253	219	0.076	1
16	133	364	0.103	-1
17	148	993	0.172	-1
18	103	606	0.039	-1
19	73	268	0.161	-1
20	193	1234	0.028	-1
21	223	509	0.092	-1
22	403	703	0.081	-1
23	58	896	0.065	-1
24	493	558	0.124	-1
25	433	944	0.097	-1

26	328	74	0.113	1
27	358	461	0.060	-1
28	448	1283	0.167	-1
29	463	316	0.033	1
30	388	1428	0.044	-1

#### 4.支持向量机 SLM 工艺参数寻优

以表 2 的数据作为输入，使用 R 语言工作平台，构造基于 SVM 的工艺参数寻优模型。优化结果如图 5 所示，最优工艺参数为功率 390W、扫描速度 300mm/s、线间距 0.14mm。在最优工艺参数下，零件上表面平整光滑，如图 6 所示，且内部无裂纹气孔等缺陷，如图 7 所示。结果表明，该方法对 SLM 过程的优化是有效的。




图 5 SVM 工艺参数优化结果




图 6 最优工艺参数下零件上表面



图 7 最优工艺参数下零件横截面